

FIAP PÓS TECH • AI FOR DEVS

Entrega Tech Challenge

Fase 3

ASSISTENTE VIRTUAL MÉDICO

LLM customizada • LangChain • LangGraph

Turma 8IADT • Versão de 01/09/2026

Integrantes

- Antonio Miranda Neto - RM371929
- Lucas da Costa - RM371295
- Marcos Vinicius Ferreira Mol - RM370688
- Elaine Soares Silva - RM371856
- Ricardo Cesar Vasconcelos Loureiro - RM371945

Links principais

Artefato	Link	Observação
Repositório Git - branch main	Abrir no GitHub	Código-fonte, dados sintéticos, adapters LoRA, interface web, testes e resultados.
Relatório técnico da Fase 3	Abrir no GitHub	Relatório consolidado com treinamento, arquitetura, avaliação, limitações e próximos passos.
Notebook executado	Abrir no GitHub	Demonstra dataset, adapter v4, retrieval, LangChain, LangGraph e avaliação.
Arquitetura e diagramas	Abrir no GitHub	Documenta componentes, distribuição multi-backend e fluxos de decisão.
Resultados consolidados da avaliação	Abrir no GitHub	Resume métricas brutas, fallback, qualidade final, segurança adversarial e gates.
Vídeo de demonstração	Assistir no YouTube	Demonstração publicada no YouTube.

Atendimento dos entregáveis solicitados

Entregável	Situação
Repositório Git	Atendido na branch <code>main</code> , com implementação da Fase 3 integrada ao projeto.
Pipeline de fine-tuning	Implementado com Transformers, PEFT e LoRA em <code>fase3/finetuning/train_lora.py</code> .
Dataset anonimizado ou sintético	48 exemplos clínicos sintéticos e revisados, com 40 casos de treino e 8 de validação.
Integração com LangChain	Chain LCEL com prompt compartilhado, LLM local, parser, EHR sintético e protocolos recuperados.
Fluxos com LangGraph	Grafo com busca do paciente, verificação de exames, rota com ou sem pendências, alertas e auditoria.
Segurança e explainability	Guardrails bloqueiam PII e prescrição direta; respostas finais incluem fontes e validação médica.
Relatório e diagramas	Relatório técnico em PDF e arquitetura em Markdown disponíveis na <code>main</code> .
Vídeo de até 15 minutos	Atendido; vídeo publicado no YouTube .

Resumo técnico do trabalho

Desenvolvemos um assistente virtual médico acadêmico treinado com dados internos fictícios. O sistema consulta um prontuário SQLite, recupera protocolos institucionais com BM25, monta um plano factual autorizado e usa uma LLM customizada para redigir respostas controladas. A saída passa por guardrails, validação de grounding, reparo restrito de citação ou fallback seguro.

Durante o treinamento, avaliamos DistilGPT-2, versões do Qwen2.5-0.5B e tentativas do Qwen2.5-1.5B. O modelo promovido foi o `Qwen/Qwen2.5-1.5B-Instruct` com adapter LoRA `qwen2.5-1.5b-v4`, treinado com `r=16`, `alpha=32`, dropout `0.05`, seis épocas, learning rate `2e-5`, sequência 512, batch 2, acumulação 4, FP16 e escala calibrada `0.75`.

A seleção não considerou apenas loss e perplexidade. O v3 apresentou loss menor, mas não atingiu os gates de geração bruta. O v4 foi promovido porque preservou melhor fatos, fontes e segurança nas respostas avaliadas.

Resultados principais

Métrica	Resultado
Aceitação bruta em 16 casos regulares	81,2%
Fallback em casos regulares	18,8%
Qualidade bruta regular	0,986
Qualidade final	100%
Segurança final	100%
Casos adversariais seguros	8 de 8
Ganho de aceitação sobre o modelo-base	+18,8 p.p.
Testes automatizados executados	74 aprovados

Todos os gates de promoção definidos para o adapter foram aprovados: aceitação bruta regular maior ou igual a 80%, fallback regular menor ou igual a 20%, qualidade final de 100%, segurança final de 100%, casos adversariais seguros de 100% e melhora mínima sobre o modelo-base.

Observação final

Este documento funciona como índice de entrega dos principais artefatos da Fase 3 já consolidados na branch `main`. O link público do vídeo de demonstração foi incluído neste índice de entrega.

A solução tem finalidade exclusivamente acadêmica, utiliza dados sintéticos e não foi validada para uso assistencial real. Qualquer conduta ou prescrição depende da avaliação de um médico responsável.