

Entrega Tech Challenge - Fase 3

Projeto: Assistente Virtual Médico com LLM Customizada, LangChain e LangGraph

Curso: FIAP Pós Tech - AI for Devs

Turma: 8IADT

Data da versão: 23/08/2026

Integrantes

Antonio Miranda Neto - RM371929

Lucas da Costa - RM371295

Marcos Vinicius Ferreira Mol - RM370688

Elaine Soares Silva - RM371856

Ricardo Cesar Vasconcelos Loureiro - RM371945

Links principais

Repositório Git - branch da Fase 3

https://github.com/netomantonio/tech-challenge-1/tree/feature/fase3_3

Contém o código-fonte, os dados sintéticos, os adapters LoRA, a interface web local, os testes e os artefatos de avaliação.

Relatório técnico da Fase 3

https://github.com/netomantonio/tech-challenge-1/blob/feature/fase3_3/relatorio_tecnico_fase3.md

Apresenta o processo de treinamento, a comparação dos modelos, a arquitetura, os resultados e as limitações do trabalho.

Notebook executado - demonstração técnica

https://github.com/netomantonio/tech-challenge-1/blob/feature/fase3_3/notebooks/04_assistente_medico_fase3.ipynb

Demonstra o dataset, o adapter v4 local, o retrieval, o assistente LangChain, o fluxo LangGraph e os resultados da avaliação.

Arquitetura e diagramas

https://github.com/netomantonio/tech-challenge-1/blob/feature/fase3_3/docs/arquitetura_fase3.md

Documenta os componentes e os fluxos de decisão do assistente virtual médico.

Resultados consolidados da avaliação

https://github.com/netomantonio/tech-challenge-1/blob/feature/fase3_3/resultados/fase3/resumo_avaliacao_assistente.json

Resume as métricas de geração bruta, fallback, qualidade final e segurança adversarial.

Vídeo de demonstração

PENDENTE: inserir o link do vídeo após a gravação e publicação.

O roteiro de 12 a 14 minutos está em docs/script_video_demonstracao_fase3.txt e contempla treinamento, funcionamento da LLM, fluxo automatizado, respostas contextualizadas, logs e validação.

Atendimento dos entregáveis solicitados

Repositório Git	A branch feature/fase3_3 concentra a implementação atual da Fase 3.
Pipeline de fine-tuning	Implementado com Transformers, PEFT e LoRA em fase3/finetuning/train_lora.py.
Dataset anonimizado ou sintético	O projeto utiliza 48 exemplos clínicos sintéticos e revisados, divididos em 40 casos de treino e 8 de validação.
Integração com LangChain	A chain LCEL combina prompt compartilhado, LLM local, parser, prontuário estruturado e protocolos recuperados.
Fluxos com LangGraph	O grafo verifica o paciente, identifica exames pendentes, escolhe a rota, emite alertas e registra a auditoria.
Segurança e explainability	Guardrails bloqueiam prescrição direta e PII; as respostas finais apresentam fontes e exigem validação médica.
Relatório e diagrama	O relatório técnico e o documento de arquitetura registram o processo, as decisões e os resultados.
Vídeo de até 15 minutos	Roteiro concluído; gravação, publicação e inclusão do link ainda pendentes.

Resumo técnico do trabalho

Desenvolvemos um assistente virtual médico acadêmico treinado com dados internos fictícios. O sistema consulta um prontuário SQLite, recupera protocolos institucionais com BM25 e utiliza uma LLM customizada para redigir respostas baseadas em um plano factual autorizado.

Durante o treinamento, avaliamos DistilGPT-2, duas versões do Qwen2.5-0.5B e duas tentativas do Qwen2.5-1.5B. O modelo promovido foi o Qwen2.5-1.5B-Instruct v4, treinado com LoRA $r=16$, $\alpha=32$, dropout 0,05, seis épocas, learning rate $2e-5$ e escala de inferência 0,75.

A seleção não considerou apenas loss e perplexidade. O v3 apresentou loss menor, mas não atingiu os gates de geração. O v4 foi promovido por preservar melhor os fatos, as fontes e a segurança nas respostas.

Resultados principais

Métrica	Resultado
Aceitação bruta em 16 casos regulares	81,2%
Fallback em casos regulares	18,8%
Qualidade final	100%
Segurança final	100%
Casos adversariais seguros	8 de 8
Ganho de aceitação sobre o modelo-base	+18,8 p.p.
Testes automatizados	56 aprovados

Observação final

Este PDF é um esboço do documento de entrega e funciona como índice dos principais artefatos da Fase 3. Antes do envio definitivo, a equipe deve substituir o aviso de vídeo pendente pelo link público da gravação e confirmar a data final da entrega.

A solução tem finalidade exclusivamente acadêmica, utiliza dados sintéticos e não foi validada para uso assistencial real. Qualquer conduta ou prescrição depende da avaliação de um médico responsável.