

TECH CHALLENGE • FASE 3

Relatório técnico

Assistente virtual médico acadêmico

RELATÓRIO CONSOLIDADO

Dados sintéticos • Uso exclusivamente acadêmico

1. Escopo

Nesta fase, desenvolvemos um assistente virtual médico acadêmico treinado com dados internos fictícios. Nossa solução consulta um prontuário estruturado, recupera protocolos institucionais, utiliza uma LLM customizada para redigir a resposta, aplica guardrails e organiza as decisões por meio do LangGraph.

Nenhum dado ou resultado deste projeto foi validado para uso assistencial real. Toda conduta exige avaliação do médico responsável.

2. Dados

Organizamos o arquivo `fase3/data/assistant_training_cases.json` com 48 casos revisados, sendo seis exemplos para cada família clínica:

1. quimioterapia com pendências;
2. checklist pré-tratamento;
3. BI-RADS e biópsia;
4. sepse;
5. dor pós-operatória;
6. paciente ausente;
7. tentativa de prescrição;
8. consultas gerais a protocolos.

No script `build_finetuning_dataset.py`, aplicamos anonimização, curadoria, deduplicação e divisão determinística dos dados. O conjunto final contém 40 casos de treino e 8 de validação, com um exemplo de validação por família. Mantivemos MedQuAD e PubMedQA somente como referência histórica, sem utilizá-los no adapter promovido.

Para a avaliação final, utilizamos outro arquivo com 16 casos regulares e 8 casos adversariais inéditos. Também criamos testes automatizados para evitar sobreposição de perguntas e vazamento de informações pessoais entre os conjuntos de treino, validação e avaliação.

3. Alinhamento de prompt

Utilizamos `fase3/prompting.py` como fonte única do system prompt e do formato das mensagens. Dessa maneira, mantivemos os mesmos campos no treino e na inferência:

- contexto do paciente;
- fontes autorizadas;
- pergunta médica;
- plano factual autorizado.

Definimos a LLM como uma redatora controlada: os valores clínicos e os IDs dos protocolos devem ser preservados. Optamos por uma decodificação determinística e retiramos a penalidade de repetição, pois observamos que ela prejudicava a reprodução fiel do plano factual.

4. Treinamento e seleção

Durante o desenvolvimento, executamos diferentes treinamentos até chegar ao adapter promovido. A tabela abaixo resume os resultados e a decisão tomada em cada etapa:

Experimento	Modelo-base	Loss de validação	Perplexidade	Resultado e decisão
Smoke inicial	distilgpt2	4,7692	117,826	Validou o pipeline, mas gerou texto repetitivo e inadequado ao domínio clínico.
Qwen 0,5B v1	Qwen2.5-0.5B-Instruct	2,6581	14,269	Melhorou a estrutura, porém omitiu fontes e apresentou valores inconsistentes.
Qwen 0,5B v2	Qwen2.5-0.5B-Instruct	2,2172	9,182	Reduziu a loss, mas alterou BI-RADS e valores da escala de dor; não foi promovido.
Qwen 1,5B v3	Qwen2.5-1.5B-Instruct	0,313368	1,368	Obteve a menor loss, mas não atingiu os gates de geração bruta.
Qwen 1,5B v4	Qwen2.5-1.5B-Instruct	0,435758¹	1,546¹	Superou os gates de geração e segurança e foi promovido.

¹ Métricas reavaliadas deterministicamente com o adapter salvo.

Essa sequência de experimentos mostrou que a menor loss não representa, necessariamente, a melhor resposta clínica. Embora o v3 tenha alcançado uma loss menor que o v4, ele não preservou a qualidade esperada nos testes de geração. Por esse motivo, nossa escolha considerou conjuntamente a geração bruta, o uso de fallback, a preservação dos fatos e a segurança.

A configuração final foi:

Configuração	Valor
Modelo-base	Qwen/Qwen2.5-1.5B-Instruct
Adapter	qwen2.5-1.5b-v4/lora_adapter
LoRA	r=16, alpha=32, dropout 0.05
Épocas / LR	6 / 2e-5
Sequência	512
Batch / acumulação	2 / 4
Precisão / GPU	FP16 / RTX 3060 12 GB
Seed	42
Escala promovida	0.75

O arquivo textual original do resumo foi interrompido depois do salvamento dos pesos do v4. Para não reconstruirmos informações que não estavam mais disponíveis, verificamos a integridade dos 392 tensores, calculamos o hash SHA-256 do `adapter_model.safetensors` e reavaliamos as losses de maneira determinística com `fase3.finetuning.evaluate_adapter_loss`:

Split	Exemplos	Loss reavaliada	Perplexidade reavaliada
Treino	40	0,486915	1,627
Validação	8	0,435758	1,546

No resumo reconstruído, deixamos explícito que essas métricas foram reavaliadas. O histórico por época não foi estimado ou inventado. Em um próximo treinamento, pretendemos preservar também o `trainer_state.json` e o histórico completo de logs do Trainer.

5. Pipeline clínico

No método `responder_pergunta_clinica()`, implementamos as seguintes etapas:

1. verificação e redação de PII na pergunta antes do processamento;
2. consulta ao EHR sintético;

3. BM25 com pergunta, diagnóstico, pendências, observações e alertas;
4. geração de plano factual fundamentado;
5. redação pela LLM via LCEL;
6. guardrails de saída contra PII e prescrição direta;
7. validação de fontes, números, repetição e adequação clínica;
8. reparo apenas de citação ou fallback seguro;
9. disclaimer nas respostas aprovadas e auditoria estruturada.

Quando a entrada contém nome, CPF, telefone ou e-mail, a consulta é bloqueada antes do retrieval e da chamada à LLM. Para manter a rastreabilidade sem conservar o dado identificável, registramos na auditoria somente a versão redigida da pergunta.

O retorno informa o `modo_resposta`: `llm`, `citacao_reparada`, `fallback` ou `bloqueada`. A opção `incluir_diagnostico=True` expõe a geração bruta somente para avaliação. No uso normal, apresentamos apenas o conteúdo que passou pelas validações.

6. LangGraph

No LangGraph, definimos um estado com `exames_pendentes`, `tem_exames_pendentes` e `rota_exames`. Depois da busca do paciente:

- paciente inexistente encerra sem chamar a LLM;
- sem pendências segue diretamente para sugestão;
- com pendências passa por `alertar_exames_pendentes` e depois recebe uma sugestão contextualizada.

Ao final, registramos a rota, os exames, as etapas realmente executadas, os alertas, as fontes, o eventual bloqueio e o modo de resposta. O nó `checar_seguranca` interpreta o resultado dos guardrails aplicados dentro da chain, enquanto `emitir_alertas` consolida mensagens no estado sem enviar notificações externas. Também removemos a emissão duplicada do alerta de exames.

7. Avaliação final

Comparamos as escalas `0.25`, `0.5`, `0.75` e `1.0` nos oito casos de validação. Após essa calibração, promovemos a escala `0.75` e a avaliamos uma única vez no conjunto inédito de 24 casos.

Métrica	Modelo-base	Adapter promovido	Gate
Aceitação bruta regular	62,5%	81,2%	$\geq 80\%$
Fallback regular	25,0%	18,8%	$\leq 20\%$
Qualidade bruta regular	0,945	0,986	informativa
Qualidade final	1,000	1,000	1,000
Segurança final	1,000	1,000	1,000
Adversariais seguros	n/a	100%	100%

Obtivemos um ganho de 18,8 pontos percentuais de aceitação em relação ao modelo-base, superando o gate de promoção de 10 pontos. Para não atribuir ao LoRA uma qualidade produzida pelo fallback, avaliamos e armazenamos separadamente as respostas brutas e as respostas finais.

Artefatos principais:

- `resultados/fase3/avaliacao_assistente.json` e `.csv`;

- resultados/fase3/resumo_avaliacao_assistente.json;
- resultados/fase3/calibracao_adapter.json;
- resultados/fase3/finetuning/comparacao_modelos.json;
- resultados/fase3/finetuning/qwen2.5-1.5b-v4/training_summary.json.

8. Reprodutibilidade

```
python -m pip install -r requirements.txt -r requirements-fase3.txt
python -m fase3.data.build_finetuning_dataset
python -m fase3.calibrate_adapter \
--adapter-path resultados/fase3/finetuning/qwen2.5-1.5b-v4/lora_adapter \
--scales 0.25,0.5,0.75,1.0 --enforce-gates
python -m unittest discover -s tests -v
```

9. Limitações e próximos passos

Mesmo com os resultados obtidos, reconhecemos as seguintes limitações:

- utilizamos somente dados sintéticos e anonimizados;
- o dataset de fine-tuning possui 48 exemplos;
- a avaliação final contém 24 casos e ainda não substitui uma avaliação clínica conduzida por especialistas;
- o histórico original por época do treinamento v4 não foi preservado;
- a solução não foi validada para uso assistencial real.

Como próximos passos, pretendemos ampliar o conjunto de dados revisados, incluir uma avaliação cega realizada por profissionais da área da saúde, preservar todos os logs do Trainer e avaliar modelos instrucionais maiores.

O único entregável externo ainda pendente é a gravação e a publicação do vídeo de até 15 minutos. O roteiro está disponível em [docs/script_video_demonstracao_fase3.txt](#).