

Relatorio tecnico - Tech Challenge 2

Otimizacao de modelos de diagnostico por algoritmos geneticos

1. Objetivo e base da continuacao

Este trabalho estende o notebook `01_cancer_mama.ipynb`, que classifica tumores como malignos (0) ou benignos (1) a partir do Wisconsin Breast Cancer Diagnostic Dataset. Foram mantidos:

- 569 amostras e 30 features numericas;
- remocao das colunas `id` e `diagnosis` antes da modelagem;
- divisao treino/teste estratificada de 80/20, com `random_state=42`;
- Regressao Logistica, KNN e Arvore de Decisao como modelos avaliados;
- `recall` da classe Maligno como metrica clinica prioritaria.

O objetivo novo e otimizar hiperparametros desses modelos via algoritmo genetico (AG), comparar o resultado contra os modelos originais e fornecer uma arquitetura de inferencia monitoravel e escalavel.

2. Implementacao do algoritmo genetico

O AG foi implementado em `src/genetic_optimization.py`, sem bibliotecas especializadas de otimizacao. Um cromossomo e uma tupla de indices que aponta para valores permitidos de hiperparametros.

Modelo	Genes otimizados
Regressao Logistica	C, penalty, class_weight
KNN	n_neighbors, weights, p
Arvore de Decisao	max_depth, min_samples_split, min_samples_leaf, criterion, class_weight

Operadores implementados:

Operador	Estrategia
Selecao	Torneio com tres individuos
Cruzamento	Uniforme, selecionando cada gene de um dos pais
Mutacao	Troca aleatoria de alelo por gene conforme taxa configurada
Elitismo	Preservacao do melhor individuo da geracao

A funcao fitness prioriza o risco clinico de falso negativo:

$$\text{fitness} = 0.65 * \text{recall_maligno} + 0.25 * \text{f1_maligno} + 0.10 * \text{accuracy}$$

Para impedir vazamento de dados, a fitness usa apenas a particao de treino, com validacao cruzada estratificada de 5 folds. O teste com 114 amostras e usado somente depois da selecao para relatar o desempenho final.

3. Experimentos realizados

As tres configuracoes exigidas foram aplicadas individualmente aos tres modelos, gerando nove execucoes:

Experimento	Populacao	Geracoes	Cruzamento	Mutacao
E1 - populacao pequena / mutacao baixa	8	6	0,80	0,08
E2 - balanceado	12	8	0,85	0,15
E3 - exploratorio	16	10	0,90	0,30

Melhores fitness por execucao, calculadas em validacao cruzada:

Modelo	E1	E2	E3	Configuracao selecionada
Regressao Logistica	0,9686	0,9753	0,9753	E2, por ordem deterministica de selecao
KNN	0,9530	0,9530	0,9530	E1, por ordem deterministica de selecao
Arvore de Decisao	0,9209	0,9275	0,9259	E2

Parametros escolhidos:

Modelo	Parametros selecionados pelo AG
Regressao Logistica	C=1.0, penalty=l2, class_weight=balanced
KNN	n_neighbors=3, weights=distance, p=1
Arvore de Decisao	max_depth=5, min_samples_split=6, min_samples_leaf=4, criterion=gini, class_weight=None

4. Comparacao final com os modelos originais

Resultados sobre o mesmo teste reservado da Fase 1:

Modelo	Versao	Acuracia	Recall Maligno	F1 Maligno	FN Maligno	AUC-ROC Maligno
Regressao Logistica	Original	0,9825	0,9762	0,9762	1	0,9954
Regressao Logistica	AG - E2	0,9561	0,9762	0,9425	1	0,9954
KNN	Original	0,9737	0,9286	0,9630	3	0,9884
KNN	AG - E1	0,9649	0,9286	0,9512	3	0,9716
Arvore de Decisao	Original	0,9386	0,9286	0,9176	3	0,9342
Arvore de Decisao	AG - E2	0,9035	0,9048	0,8736	4	0,9358

Interpretacao critica

O AG funcionou como metodo de busca e identificou configuracoes com maior fitness na validacao cruzada. Entretanto, essa melhoria de validacao nao se converteu em melhoria no teste reservado:

- a Regressao Logistica otimizada preservou o melhor recall maligno (0,9762) e um unico falso negativo, mas reduziu acuracia e F1 por produzir mais falsos positivos;
- o KNN otimizado manteve recall e falsos negativos do original, mas teve queda em F1 e AUC;
- a Arvore otimizada piorou o recall no teste.

Portanto, para uma recomendacao baseada neste teste, a **Regressao Logistica original permanece o melhor modelo observado**. O melhor individuo otimizado continua registrado nos artefatos do experimento, mas a API publica o baseline logistico, evitando servir uma configuracao inferior. Como essa decisao usa o teste reservado apos a comparacao, suas metricas nao devem ser lidas como nova estimativa imparcial de desempenho em producao.

Essa decisao tambem delimita a interpretacao com LLM. O trabalho compara os tres modelos exigidos pela Fase 2, mas o servico operacional expõe somente o pipeline recomendado em `modelo_serving.joblib`. Portanto, o endpoint `POST /interpret` explica o diagnostico produzido pelo modelo final selecionado para serving, que neste experimento foi a Regressao Logistica. Interpretar KNN e Arvore no mesmo endpoint exigiria outro contrato de API e estrategias de explicabilidade diferentes para cada familia de modelo.

5. Monitoramento e logging

O treinamento produz automaticamente:

Arquivo gerado em resultados/fase2/	Finalidade
treinamento_ga.log	Registro de fitness, recall e candidatos por geracao
experimentos_ga.csv	Resultado das nove buscas
historico_geracoes.csv	Curvas de evolucao do AG
comparacao_baseline_otimizados.csv	Comparacao final no teste
resumo_execucao.json	Parametros e metricas do campeonato
modelo_serving.joblib	Pipeline recomendado e serializado para inferencia

A API em `src/api.py` disponibiliza:

- `POST /predict`, com classe e probabilidades;
- `GET /health/live` e `GET /health/ready`;
- `GET /metrics`, compativel com Prometheus;
- logs JSON por predicao, sem registrar as features recebidas.

As metricas medem volume/status de requisicoes, distribuicao de predicoes, latencia de inferencia e disponibilidade do modelo.

6. Arquitetura escalavel

A camada de serving possui container proprio (Dockerfile) e manifestos Kubernetes em `deploy/k8s/`:

Recurso	Configuracao
Deployment	2 replicas iniciais, probes e limites de recursos
Service	Exposicao interna HTTP da API
HorizontalPodAutoscaler	2 a 10 replicas, alvo de 60% de CPU

O scale-down aguarda 300 segundos para reduzir oscilacoes de replicas. O cluster precisa do `metrics-server` para o HPA de CPU; Prometheus pode coletar `/metrics` para dashboards e alertas.

7. Integracao com LLM para interpretacao

A camada de interpretacao foi implementada em `src/llm_interpretation.py` e integrada a API pelo endpoint `POST /interpret`. A integracao usa uma LLM pre-treinada por meio da API do Groq, com modelo configuravel por ambiente.

O endpoint interpreta o resultado do modelo recomendado para serving. Embora Regressao Logistica, KNN e Arvore de Decisao sejam otimizados e comparados, a API publica apenas o campeonato

operacional da comparacao final. Por isso, as respostas de `/interpret` retornam `model: "Regressao Logistica"` quando esse e o artefato selecionado em `modelo_serving.joblib`.

A LLM nao recebe identificador do paciente. O contexto enviado contem:

- classe prevista e probabilidades de malignidade/benignidade;
- as cinco contribuicoes locais de maior magnitude da Regressao Logistica;
- insights acionaveis estruturados derivados dessas contribuicoes;
- instrucoes fixas para produzir texto orientado a revisao profissional.

7.1 Prompt engineering

O prompt `clinical_explanation_v3` obriga quatro secoes:

- 1 RESUMO DO RESULTADO;
- 2 EVIDENCIAS DO MODELO;
- 3 INSIGHTS ACIONAVEIS PARA MEDICOS;
- 4 LIMITACOES E SEGURANCA.

As instrucoes impedem que a resposta declare diagnostico confirmado ou prescreva tratamento. Tambem exigem a mencao da natureza academica do modelo, ausencia de validacao externa e necessidade de revisao clinica. Alem do texto livre, cada resposta persiste `insights_acionaveis` com sinal observado, evidencia numerica, implicacao para revisao e cautela de interpretacao.

A versao v3 acrescenta tres regras especificas para o contexto de saude da mulher: (1) situar os achados em cuidados tipicos desse contexto (ex.: acompanhamento ginecologico/mastologico) sem presumir dados nao fornecidos; (2) vedar linguagem alarmista, sentenciosa ou estigmatizante (ex.: "sentenca de morte", "fatal", "sem cura"); e (3) proibir qualquer identificador pessoal da paciente no texto gerado, reforcando privacidade e confidencialidade. As instrucoes tambem passaram a exigir que os insights acionaveis incluam proximos passos praticos (agendamento de exames, encaminhamento) pensando na realidade de acesso da paciente ao sistema de saude, sem prescrever conduta.

7.2 Avaliacao de qualidade

O modulo `src/evaluate_llm.py` seleciona casos determinísticos:

Caso	Objetivo
Alto risco maligno	Avaliar clareza em resultado de alerta
Alto risco benigno	Verificar se a resposta evita falsa seguranca
Caso proximo do limiar	Avaliar comunicacao de maior incerteza
Faixas de probabilidade	Verificar consistencia em perfis intermediarios

Cada interpretacao e avaliada por uma rubrica objetiva que verifica classe prevista, probabilidade, secoes exigidas, insights acionaveis, limitacao explicita, orientacao de revisao profissional, ausencia de prescricao e sensibilidade cultural/de genero (`sensibilidade_cultural_e_genero`, que reprova

linguagem alarmista ou estigmatizante). A rubrica normaliza acentos, Markdown e variações simples de título para reduzir falsos negativos de formatação. O endpoint também expõe contagem, latência e distribuição dessa pontuação em `/metrics`.

Com `GROQ_API_KEY` configurada, o comando abaixo regenera as tabelas reais:

```
python -m src.evaluate_llm
```

Esse comando gera `avaliacao_interpretacoes_llm.csv`, `interpretacoes_llm.json` e `resumo_avaliacao_llm.json` em `resultados/fase2/`. Na última execução, com o prompt `clinical_explanation_v3`, os 7 casos representativos atingiram `score_objetivo = 1.0` (média, mínimo e máximo), sem nenhum critério reprovado. A avaliação automática deve ser complementada por avaliação humana especializada antes de qualquer uso clínico.

8. Reprodução

```
pip install -r requirements.txt
python data/download_datasets.py
python -m src.genetic_optimization --data data/cancer_mama.csv --output resultados/fase2
uvicorn src.api:app --host 0.0.0.0 --port 8000
```

Os notebooks executáveis encontram-se em `notebooks/02_otimizacao_genetica_cancer_mama.ipynb` e `notebooks/03_interpretacao_llm_cancer_mama.ipynb`. A documentação detalhada da arquitetura encontra-se em `docs/arquitetura_fase2.md`.

9. Limitações

- O número de amostras é baixo para concluir desempenho clínico.
- Não foi feita validação com dados externos.
- Múltiplas buscas aumentam risco de selecionar configurações específicas

demais ao conjunto de treino, ainda que o teste permaneça separado.

- O sistema é acadêmico e não substitui avaliação médica.