

Relatório técnico - Tech Challenge Fase 3

1. Escopo

Nesta fase, desenvolvemos um assistente virtual médico acadêmico treinado com dados internos fictícios. Nossa solução consulta um prontuário estruturado, recupera protocolos institucionais, utiliza uma LLM customizada para redigir a resposta, aplica guardrails e organiza as decisões por meio do LangGraph.

Nenhum dado ou resultado deste projeto foi validado para uso assistencial real. Toda conduta exige avaliação do médico responsável.

2. Dados

Organizamos o arquivo `fase3/data/assistant_training_cases.json` com 48 casos revisados, sendo seis exemplos para cada família clínica:

1. quimioterapia com pendências;
2. checklist pré-tratamento;
3. BI-RADS e biópsia;
4. sepse;
5. dor pós-operatória;
6. paciente ausente;
7. tentativa de prescrição;
8. consultas gerais a protocolos.

No script `build_finetuning_dataset.py`, aplicamos anonimização, curadoria, deduplicação e divisão determinística dos dados. O conjunto final contém 40 casos de treino e 8 de validação, com um exemplo de validação por família. Mantivemos MedQuAD e PubMedQA somente como referência histórica, sem utilizá-los no adapter promovido.

Para a avaliação final, utilizamos outro arquivo com 16 casos regulares e 8 casos adversariais inéditos. Também criamos testes automatizados para evitar sobreposição de perguntas e vazamento de informações pessoais entre os conjuntos de treino, validação e avaliação.

3. Alinhamento de prompt

Utilizamos `fase3/prompting.py` como fonte única do system prompt e do formato das mensagens. Dessa maneira, mantivemos os mesmos campos no treino e na inferência:

- contexto do paciente;
- fontes autorizadas;
- pergunta médica;
- plano factual autorizado.

Definimos a LLM como uma redatora controlada: os valores clínicos e os IDs dos protocolos devem ser preservados. Optamos por uma decodificação determinística e retiramos a penalidade de repetição, pois observamos que ela prejudicava a reprodução fiel do plano factual.

4. Treinamento e seleção

Durante o desenvolvimento, executamos diferentes treinamentos até chegar ao adapter promovido. A tabela abaixo resume os resultados e a decisão tomada em cada etapa:

Experimento	Modelo-base	Loss de validação	Perplexidade	Resultado e decisão
Smoke inicial	distilgpt2	4,7692	117,826	Validou o pipeline, mas gerou texto repetitivo e inadequado ao domínio clínico.
Qwen 0,5B v1	Qwen2.5-0.5B-Instruct	2,6581	14,269	Melhorou a estrutura, porém omitiu fontes e apresentou valores inconsistentes.
Qwen 0,5B v2	Qwen2.5-0.5B-Instruct	2,2172	9,182	Reduziu a loss, mas alterou BI-RADS e valores da escala de dor; não foi promovido.
Qwen 1,5B v3	Qwen2.5-1.5B-Instruct	0,313368	1,368	Obteve a menor loss, mas não atingiu os gates de geração bruta.
Qwen 1,5B v4	Qwen2.5-1.5B-Instruct	0,435758¹	1,546¹	Superou os gates de geração e segurança e foi promovido.

¹ Métricas reavaliadas deterministicamente com o adapter salvo.

Essa sequência de experimentos mostrou que a menor loss não representa, necessariamente, a melhor resposta clínica. Embora o v3 tenha alcançado uma loss menor que o v4, ele não preservou a qualidade esperada nos testes de geração. Por esse motivo, nossa escolha considerou conjuntamente a geração bruta, o uso de fallback, a preservação dos fatos e a segurança.

A configuração final foi:

Configuração	Valor
Modelo-base	Qwen/Qwen2.5-1.5B-Instruct
Adapter	qwen2.5-1.5b-v4/lora_adapter
LoRA	r=16 , alpha=32 , dropout 0.05
Épocas / LR	6 / 2e-5
Sequência	512
Batch / acumulação	2 / 4
Precisão / GPU	FP16 / RTX 3060 12 GB
Seed	42
Escala promovida	0.75

O arquivo textual original do resumo foi interrompido depois do salvamento dos pesos do v4. Para não reconstruirmos informações que não estavam mais disponíveis, verificamos a integridade dos 392 tensores, calculamos o hash SHA-256 do `adapter_model.safetensors` e reavaliamos as losses de maneira determinística com `fase3.finetuning.evaluate_adapter_loss`:

Split	Exemplos	Loss reavaliada	Perplexidade reavaliada
Treino	40	0,486915	1,627
Validação	8	0,435758	1,546

No resumo reconstruído, deixamos explícito que essas métricas foram reavaliadas. O histórico por época não foi estimado ou inventado. Em um próximo treinamento, pretendemos preservar também o `trainer_state.json` e o histórico completo de logs do Trainer.

5. Pipeline clínico

No método `responder_pergunta_clinica()`, implementamos as seguintes etapas:

1. verificação e redação de PII na pergunta antes do processamento;
2. consulta ao EHR sintético;
3. BM25 com pergunta, diagnóstico, pendências, observações e alertas;
4. geração de plano factual fundamentado;
5. redação pela LLM via LCEL;
6. guardrails de saída contra PII e prescrição direta;
7. validação de fontes, números, repetição e adequação clínica;
8. reparo apenas de citação ou fallback seguro;
9. disclaimer nas respostas aprovadas e auditoria estruturada.

Quando a entrada contém nome, CPF, telefone ou e-mail, a consulta é bloqueada antes do retrieval e da chamada à LLM. Para manter a rastreabilidade sem conservar o dado identificável, registramos na auditoria somente a versão redigida da pergunta.

O retorno informa o `modo_resposta`: `llm`, `citacao_reparada`, `fallback` ou `bloqueada`. A opção `incluir_diagnostico=True` expõe a geração bruta somente para avaliação. No uso normal, apresentamos apenas o conteúdo que passou pelas validações.

6. LangGraph

No LangGraph, definimos um estado com `exames_pendentes`, `tem_exames_pendentes` e `rota_exames`. Depois da busca do paciente:

- paciente inexistente encerra sem chamar a LLM;
- sem pendências segue diretamente para sugestão;
- com pendências passa por `alertar_exames_pendentes` e depois recebe uma sugestão contextualizada.

Ao final, registramos a rota, os exames, as etapas realmente executadas, os alertas, as fontes, o eventual bloqueio e o modo de resposta. O nó `checar_seguranca` interpreta o resultado dos guardrails aplicados dentro da chain, enquanto `emitir_alertas` consolida mensagens no estado sem enviar notificações externas. Também removemos a emissão duplicada do alerta de exames.

7. Avaliação final

Comparamos as escalas `0.25`, `0.5`, `0.75` e `1.0` nos oito casos de validação. Após essa calibração, promovemos a escala `0.75` e a avaliamos uma única vez no conjunto inédito de 24 casos.

Métrica	Modelo-base	Adapter promovido	Gate
Aceitação bruta regular	62,5%	81,2%	$\geq 80\%$
Fallback regular	25,0%	18,8%	$\leq 20\%$
Qualidade bruta regular	0,945	0,986	informativa
Qualidade final	1,000	1,000	1,000
Segurança final	1,000	1,000	1,000
Adversariais seguros	n/a	100%	100%

Obtivemos um ganho de 18,8 pontos percentuais de aceitação em relação ao modelo-base, superando o gate de promoção de 10 pontos. Para não atribuir ao LoRA uma qualidade produzida pelo fallback, avaliamos e armazenamos separadamente as respostas brutas e as respostas finais.

Artefatos principais:

- `resultados/fase3/avaliacao_assistente.json` e `.csv`;
- `resultados/fase3/resumo_avaliacao_assistente.json`;
- `resultados/fase3/calibracao_adapter.json`;

- `resultados/fase3/finetuning/comparacao_modelos.json` ;
- `resultados/fase3/finetuning/qwen2.5-1.5b-v4/training_summary.json` .

8. Reprodutibilidade

```
python -m pip install -r requirements.txt -r requirements-fase3.txt
python -m fase3.data.build_finetuning_dataset
python -m fase3.calibrate_adapter \
    --adapter-path resultados/fase3/finetuning/qwen2.5-1.5b-v4/lora_adapter \
    --scales 0.25,0.5,0.75,1.0 --enforce-gates
python -m unittest discover -s tests -v
```

9. Limitações e próximos passos

Mesmo com os resultados obtidos, reconhecemos as seguintes limitações:

- utilizamos somente dados sintéticos e anonimizados;
- o dataset de fine-tuning possui 48 exemplos;
- a avaliação final contém 24 casos e ainda não substitui uma avaliação clínica conduzida por especialistas;
- o histórico original por época do treinamento v4 não foi preservado;
- a solução não foi validada para uso assistencial real.

Como próximos passos, pretendemos ampliar o conjunto de dados revisados, incluir uma avaliação cega realizada por profissionais da área da saúde, preservar todos os logs do Trainer e avaliar modelos instrucionais maiores.

O único entregável externo ainda pendente é a gravação e a publicação do vídeo de até 15 minutos. O roteiro está disponível em `docs/script_video_demonstracao_fase3.txt` .